

Comparing Text Representations and Chunk Selection with Abstention for Evidence Retrieval in German Examination Regulations

Research Blueprint for an Empirical Retrieval Study

Seminarteilnehmer / Verfasser
Institut für Sprache und Information
Heinrich-Heine-Universität Düsseldorf

August 30, 2026

Abstract

Conceptual abstract (blueprint; revise last after the error-analysis freeze): This study investigates evidence retrieval over a hierarchically structured German examination regulation, with explicit abstention for questions that cannot be answered from the source document. A project-specific dataset contains 720 questions, including 120 intentionally unanswerable zero-gold questions, and 201 retrieval chunks. We compare a sparse TF-IDF representation with two fixed multilingual dense representations, Sentence-BERT and multilingual E5, and evaluate four chunk-selection families: top- k , absolute thresholding, top- k with an absolute threshold, and relative-margin selection. Hyperparameters are developed only on the development split, five finalists are frozen for validation, and the validation winner is evaluated once on the held-out test split. The selected multilingual E5 top-1 + threshold configuration ($\theta = 0.83959$) achieves mean question-level evidence-selection F1 scores of 0.647 on development, 0.611 on validation, and 0.491 on test. The validation-to-test decrease motivates a separate failure analysis of retrieval errors, abstention behavior, multi-evidence limitations, evidence-group generalization, and the strict chunk-ID gold standard; causal attribution will only be made where the finalized manual audit supports it.

1 Introduction

Leitfragen für diesen Abschnitt

- **Problem und Scope:** Warum ist die präzise Identifikation von Belegstellen in einer strukturierten Prüfungsordnung ein eigenständiges Information-Retrieval-Problem? Welche Rolle spielen rechtlich nahe, aber funktional unterschiedliche Passagen, Tabellen und Studienverlaufsinformationen?
- **Retrieval als vorgelagerte Komponente:** Warum wird in dieser Arbeit isoliert *Evidence Retrieval* bzw. Evidence-Set Prediction untersucht, statt generierte Antworten oder End-to-End-QA zu evaluieren? Wie ordnet sich Retrieval als vorgeschaltete Komponente wissensintensiver QA/RAG-Systeme ein, ohne daraus eine Garantie gegen Halluzinationen abzuleiten?
- **Abstention:** Warum muss das System für plausibel klingende, aber aus der Quelle nicht beantwortbare Fragen explizit [] vorhersagen können?

- **Research Questions:**

- **RQ1 – Representation:** How do sparse lexical and dense semantic representations differ in their ability to retrieve answer-supporting chunks from a German examination regulation?
 - **RQ2 – Selection and abstention:** How do different chunk-selection and abstention strategies affect evidence-retrieval performance and abstention behavior?
 - **RQ3 – Generalization and failure modes:** How well does the selected configuration generalize to the held-out test split, and which observed failure modes and split/evaluation properties are associated with its remaining errors?
- **Contributions vorsichtig rahmen:** Empirischer Vergleich der drei Repräsentationen; separater Vergleich der Selektions-/Abstentionsregeln; projekt-spezifischer kuratierter Retrieval-Datensatz; leakage-aware Evaluationsdesign; Fehleranalyse des eingefrorenen Systems. Keine “first”, SOTA- oder allgemeine Überlegenheitsbehauptung.

Empfohlene Quellen & Zitationszweck

- **?:** Primärquelle dafür, Retrieval als explizite nicht-parametrische Wissenskomponente in wissensintensiven NLP-/QA-Systemen zu motivieren. Nicht als Beleg verwenden, dass das hier untersuchte Retrieval Halluzinationen verhindert.
- **?:** Grundlegende Dense-Passage-Retrieval-Arbeit für Open-Domain-QA; geeignet zur Einordnung von Bi-Encoder-Retrieval.
- **?:** Analogie für die wissenschaftliche Bedeutung unbeantwortbarer Fragen und expliziter No-Answer-Entscheidungen.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- Gegenstand: Prüfungsordnung 2026 für den BA Computerlinguistik im untersuchten Dokumentkorpus.
- Prediction Target: Menge von Retrieval-Chunk-IDs; keine generierte Antwortqualität.
- Primäre Metrik: mean question-level evidence-selection F1.
- Offizieller eingefrorener Test-Endpunkt: $F1 = 0.4907$ bei 144/144 eingereichten und ausgewerteten Prediction Records.

2 Motivation and Related Work

Leitfragen für diesen Abschnitt

- **Sparse vs. dense retrieval:** Welche Grundlagen des Vektorraummodells und von TF-IDF sind für den Vergleich mit neuronalen Satz-/Passage-Embeddings relevant?
- **Generic semantic similarity vs. retrieval-oriented encoding:** Welche methodische Differenz besteht zwischen einem allgemeinen multilingualen Sentence-BERT-Checkpoint und E5 als retrieval-orientierter Text-Embedding-Familie? Nur als Moti-

vation formulieren, nicht als kausale Erklärung des Projektergebnisses.

- **Zero-shot robustness:** Was zeigt BEIR tatsächlich? Insbesondere: BM25 bleibt auf heterogenen Zero-Shot-Retrieval-Tasks eine starke lexikalische Baseline. Daraus nicht ableiten, BEIR beweise die projektspezifische Stärke von TF-IDF aufgrund administrativer Fachterminologie.
- **Selective prediction / abstention:** Wie motivieren Reject-Option und unanswerable QA das bewusste Zurückweisen unsicherer bzw. nicht belegbarer Anfragen?
- **Legal/regulatory retrieval context:** Welche Arbeiten zeigen, dass juristische Retrieval-Aufgaben und strukturell ähnliche Rechtsdokumente besondere Evidenz-Disambiguierung erfordern?
- **Research positioning:** Die Arbeit als kontrollierte Fallstudie in einem kleinen deutschen regulatorischen Korpus positionieren. Keine unbelegte Behauptung, erstmals Prüfungsordnungs-Retrieval zu untersuchen.

Empfohlene Quellen & Zitationszweck

- **Sparse Retrieval:** ? für Term Specificity/IDF und ? für das klassische Vektorraummodell.
- **Sentence Embeddings:** ? für Sentence-BERT sowie ? für multilinguale Sentence-Embedding-Distillation.
- **Retrieval Embeddings:** ? und ? für die E5-Familie.
- **Benchmarks:** ? für heterogene Zero-Shot-IR-Evaluation und die Robustheit von BM25; ? für task-übergreifende Embedding-Evaluation.
- **Abstention:** ? für Selective Prediction / Reject Option; ? für unanswerable QA.
- **Deutsche Rechtsdomäne:** ? und ? zur Einordnung deutscher Legal-IR-/QA-Aufgaben.
- **Aktueller Legal-Retrieval-Kontext:** ? zeigt aktuelle Retrieval-Probleme in großen, strukturell ähnlichen juristischen Dokumentbeständen. Die Aufgabe ist nicht identisch mit dem hier untersuchten Einzelkorpus; die Quelle dient nur der Domänenpositionierung.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- Related Work kompakt halten; keine breite Legal-NLP-Historie.
- TF-IDF-Erklärung im Results-Teil nur als *plausible explanation*: hohe lexikalische Spezifität wurde nicht als Kausalmechanismus experimentell isoliert.
- Sentence-BERT nur als im vorliegenden Setting schwächere Repräsentation beschreiben; keine Generalisierung auf Legal NLP insgesamt.

3 Methodology

Leitfragen für diesen Abschnitt

- **Text representations:**

- *TF-IDF*: Tatsächlich ausgeführte Konfiguration: `TfidfVectorizer(lowercase=True, ngram_range=(1,3))`. Das Vocabulary wird auf den Chunk-Texten gefittet; die Fragen werden anschließend in denselben Raum transformiert. Keine sublineare TF-Skalierung behaupten, da `sublinear_tf` nicht gesetzt wurde.
- *Sentence-BERT*: Tatsächlich verwendeter Checkpoint: `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` (384-dimensionale Sentence Embeddings). Kein selbst implementiertes Mean-Pooling behaupten; die Repräsentation wird über `SentenceTransformer` erzeugt.
- *Multilingual E5*: Checkpoint `intfloat/multilingual-e5-base` (768 Dimensionen). Fragen werden mit `query:` und Chunks mit `passage:` präfixiert.
- Keine der beiden dichten Repräsentationen wurde auf dem Projektkorpus fine-tuned.

- **Similarity:** Für jede Repräsentation wird Cosine Similarity zwischen allen 720 Fragen und 201 Chunks berechnet. Die resultierende Matrix hat 720×201 Einträge. Bei den neuronalen Encodern wurde `normalize_embeddings=False` verwendet; daher nicht behaupten, die gespeicherten dichten Vektoren seien vorab L2-normalisiert. Die Cosine Similarity selbst normiert durch die Vektornormen.

- **Selector families:**

1. *Top-k*:

$$S_{\text{top-}k}(q) = \text{argtop}_k\{s(q, c_i)\}.$$

Gibt bei ausreichender Collection immer k Chunks zurück und kann allein nicht abstainieren.

2. *Absolute threshold*:

$$S_{\theta}(q) = \{c \in \mathcal{C} \mid s(q, c) \geq \theta\}.$$

Kann $[]$ oder mehrere Chunks zurückgeben.

3. *Top-k + threshold*: Zunächst threshold-passing Chunks nach Score ordnen, dann höchstens die ersten k zurückgeben. Damit werden absolute Filterung, Abstention und Output-Size-Control kombiniert.

4. *Relative margin*: Mit s_k als Score auf Rang k und s_{k+1} als folgendem Score gilt

$$m_k(q) = \frac{s_k - s_{k+1}}{\max(|s_k|, 10^{-12})}.$$

Top- k wird nur ausgegeben, wenn $m_k(q) \geq \gamma$; andernfalls wird $[]$ vorhergesagt. Für $k = 1$ misst dies die relative Trennung zwischen Rang 1 und Rang 2.

- **Threshold search regions:** Erklären, dass repräsentationsspezifische Regionen auf Development aus robusten Quantilen von worst-gold, best-non-gold und Zero-Gold-Top-Scores abgeleitet wurden; der eigentliche Sweep wurde ausschließlich auf Development ausgewertet.

Empfohlene Quellen & Zitationszweck

- ?: Vektorraumdarstellung und Cosine-Ähnlichkeit als klassische IR-Grundlage.
- ?, ?: Sentence-BERT und multilinguale Sentence Embeddings.
- ?, ?: Retrieval-orientiertes E5-Training und multilingualer E5-Kontext.
- ?: Konzeptionelle Grundlage für Selective Prediction; die konkrete Similarity-Threshold-Regel bleibt eine Designentscheidung dieses Experiments.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- Frozen Paper Comparison: TF-IDF, Sentence-BERT, E5; Cosine Similarity; Top- k , Threshold, Top- k +Threshold, Relative Margin.
- Nicht in die Story aufnehmen: im Code zusätzlich vorhandene Dot-/Euclidean-Funktionen oder `softmax_cumulative`, da sie nicht zu den eingefrorenen vier Selector-Familien des Papers gehören.
- Recorded initial threshold search regions: E5 0.8331–0.8865; TF-IDF 0.0591–0.5162; Sentence-BERT 0.4740–0.7595.

4 Experimental Setup

Leitfragen für diesen Abschnitt

- **Corpus and chunking:**
 - Wie wurden die 201 aktiven Retrieval-Chunks aus General Regulation, program-specific appendix, exemplary study plan und front matter gebildet?
 - Welche Kontext-Header sorgen dafür, dass kurze Tabellen-/Appendix-Werte außerhalb ihrer Originalseite interpretierbar bleiben?
 - Welche finalen Qualitätschecks bestanden die Chunks (eindeutige IDs, keine leeren Chunks, vollständige Quellreihenfolge)?
- **Question and gold construction:**
 - 720 Fragen insgesamt: 600 answerable und 120 zero-gold.
 - Gold-Ziel ist `all_required_chunk_ids`: ein *minimal intended complete evidence set*, nicht notwendigerweise die exhaustive Menge aller semantisch validen Alternativbelege.
 - **TODO – provenance freeze:** Vor finaler Prosa exakt dokumentieren, welche Schritte bei Chunking, Fragenerstellung, Mapping und Audit menschlich, skript-gestützt bzw. ggf. sprachmodellassistent waren. Keine “fully manual”- oder “LLM-generated”-Story erfinden.
- **Leakage-aware split:**
 - Development/Validation/Test: 432/144/144 Fragen.
 - Gruppierungsregel `same_non_empty_gold_chunk_set`: Fragen mit identischem nicht-leerem Gold-Evidence-Set bleiben im selben Split.

- Split-Integrität: 315 Gruppen; größte Gruppe 13 Fragen; keine non-empty Gold-Set-Gruppe überschreitet Splits; Zero-Gold-Fragen sind Singleton-Gruppen.
- Trade-off: weniger Evidence Leakage, aber strengere Generalisierung zu komplett ungesesehenen Evidence-Gruppen.
- **Selection protocol:**
 - Selector-/Hyperparameterentwicklung nur auf Development.
 - Ranking: mean question-level F1; dokumentierte Tie-Breaks: Exact Match, Precision, dann weniger ausgewählte Chunks.
 - Fünf Finalisten vor Validation einfrieren; keine post-validation Retuning-Schleife; einen Validation-Sieger einfrieren; genau diesen einmal auf Test evaluieren.
- **Evaluation:**
 - Gold = [] und Pred = [] ergibt Precision=Recall=F1=1 und Exact Match.
 - Gold = [], Pred ≠ [] sowie Gold ≠ [], Pred = [] ergeben pro Frage F1=0.
 - Ein komplett fehlender Prediction Record ist semantisch anders als ein explizites []: fehlende Records werden aus den Means ausgeschlossen und als unanswered gezählt. Die eingefrorene Testauswertung weist 144/144 submitted/evaluated und 0 unanswered aus.
 - Secondary metrics: mean question precision/recall, Exact Match, Micro F1, zero-gold abstention, empty-selection rate, average selected chunks.
- **Baselines:**
 - *Random Top-1*: uniformer Zufallschunk; 100 feste Seeds 0–99; mean ± standard deviation berichten.
 - *Most-Frequent Development Answer*: häufigstes nicht-leeres exaktes Gold-Set auf Development einmal einfrieren und für Validation/Test konstant vorhersagen.
 - *Always Abstain*: für jede Frage [].
 - **TODO**: Finale autoritative Test-Baseline-Werte direkt aus dem eingefrorenen Baseline-Output einsetzen; nicht aus Erinnerung rekonstruieren.

Empfohlene Quellen & Zitationszweck

- **?**: Literaturkontext für bewusst unbeantwortbare Fragen; die konkrete Zero-Gold-Konstruktion ist projektspezifisch.
- **?**: Kontext für standardisierte Embedding-/Retrieval-Evaluation; die konkrete mean-set-F1-Definition des Projekts muss dennoch selbst explizit definiert werden.

Verbindliche experimentelle Eckdaten / offene Verifikationen

Verifizierte Gold-Set-Verteilung.

Split	Gesamt	Zero-Gold	1-Gold	2-Gold
Development	432	74	340	18
Validation	144	24	116	4
Test	144	22	112	10
Gesamt	720	120	568	32

- 201 aktive Retrieval-Chunks; 10,194 Wörter; mittlere Chunklänge 50.72 Wörter; Median 41; Range 8–204 Wörter.
- Source-layer-Verteilung aus dem Quality Audit: 133 General Regulation, 36 Exemplary Study Plan, 30 Program Appendix, 2 Front Matter.
- Die Chunking-Collection ist als `ready_with_minor_issues` auditiert; dokumentierte kleinere Source-/Format-Risiken nicht als kaputtes Preprocessing darstellen.
- **TODO reproducibility:** materiell relevante Python-/Library-Versionen vor Manuscript Freeze eintragen.

5 Results and Evaluation

Leitfragen für diesen Abschnitt

- **RQ1 – Representation comparison:**
 - E5 erreicht auf Development die stärksten Werte unter den evaluierten Repräsentationen.
 - TF-IDF bleibt in diesem Korpus konkurrenzfähig. Zulässige Interpretation: Die hohe lexikalische Spezifität des Korpus ist eine plausible Erklärung; sie wurde nicht als Kausalmechanismus isoliert gemessen.
 - Der evaluierte multilingual MiniLM Sentence-BERT-Checkpoint liegt im betrachteten Setting hinter E5 und TF-IDF. Keine Generalisierung wie “Sentence-BERT funktioniert nicht für Rechtstexte”.
- **RQ2 – Selector and abstention:**
 - Nicht nach einem universell “überlegenen” Selector fragen, sondern nach Trade-offs zwischen Evidence Retrieval, Output-Size-Control und Abstention.
 - Plain Top-1 ist stark, kann aber nie abstainieren. Pure Threshold kann abstainieren, kann jedoch viele Chunks selektieren und dadurch Precision verlieren.
 - Top-1 + absolute threshold erzeugt die stärkste E5-Konfiguration auf Development und bleibt der Validation-Sieger; Relative Margin ist konkurrenzfähig, insbesondere für E5/TF-IDF, aber nicht der finale Validation-Sieger.
 - Wichtig: Für TF-IDF ist Relative Margin auf Development geringfügig stärker als Top-1+Threshold; daher keine universelle Selector-Rangordnung behaupten.
- **Validation and frozen model selection:**

- E5 + Top-1 + Threshold 0.83959: $F1 = 0.6111$, $EM = 0.5972$, mean Precision = 0.6181, mean Recall = 0.6076, zero-gold abstention = 0.4167.
 - Nur die fünf eingefrorenen Finalisten wurden auf Validation verglichen; Sentence-BERT war nicht unter diesen fünf Finalisten. Daher Validation nicht als erneuten vollständigen Drei-Repräsentationen-Vergleich formulieren.
- **RQ3 – Held-out test:**
 - Offizieller Test: $F1 = 0.4907$, $EM = 0.4861$, mean Precision = 0.4931, mean Recall = 0.4896, Micro $F1 = 0.5041$.
 - Empty-selection rate = 0.2083; Zero-Gold-Abstention = $9/22 = 0.4091$. Das System zeigt sowohl false abstentions/under-retrieval als auch false-positive retrievals bei Zero-Gold.
 - Validation-to-Test-Drop: ca. 0.1204. Keine Aussage, dieser Drop sei “within normal SD”, solange keine entsprechende Unsicherheitsanalyse durchgeführt wurde.
 - **Error analysis – vor finaler Prosa einfrieren:**
 1. *Structural multi-evidence limitation:* Bei echten 2-Gold-Fragen kann ein Top-1-System nie ein exact full-set match erzielen. Wenn genau einer der zwei Gold-Chunks korrekt geliefert wird, ist maximal $P = 1$, $R = 0.5$, $F1 = 2/3$. Im Test gibt es 10 2-Gold-Fragen.
 2. *Answerable abstentions* vs. *zero-gold false positives* getrennt quantifizieren.
 3. *Unseen evidence-group case:* Gruppe G0040 umfasst acht Testfragen Q0153–Q0160 mit demselben Gold-Chunk und ohne gleiches non-empty Gold-Set in Dev/Val. In der bisherigen Wrong-Chunk-Review tauchen sechs dieser IDs auf. **TODO:** Q0157 und Q0160 bzw. alle acht Outcomes direkt aus der finalen Per-Question-Evaluation prüfen, bevor ein Whole-Cluster-Failure-Claim geschrieben wird.
 4. *Gold-standard strictness:* Erst nach abgeschlossener manueller Review quantitativ behaupten, wie viele formal falsche Chunk-ID-Predictions ausreichende alternative Evidence enthalten.
 5. *Post-hoc diagnostics:* Eine Sensitivitätsrechnung (z. B. der historische ~ 0.577 -Wert) nur aufnehmen, wenn Annahmen und Counts final verifiziert sind; niemals als “corrected test score” darstellen.
 - **Baseline comparison: TODO:** Frozen test baseline table erst nach direkter Verifikation der autoritativen Baseline-Outputs ausfüllen.

Empfohlene Quellen & Zitationszweck

- **?:** Nur zur allgemeinen Einordnung starker lexikalischer Zero-Shot-Baselines; nicht als Beweis der projektspezifischen TF-IDF-Ursache.
- **?:** Aktueller Domänenkontext dafür, dass Retrieval in strukturell ähnlichen juristischen Beständen fehleranfällig sein kann; keine direkte Erklärung einzelner Projektfehler.
- **Eigene eingefrorene Evaluation:** Alle Zahlen und Error-Counts aus Projektartefakten berichten; Literatur darf diese Messergebnisse nicht ersetzen.

Verbindliche experimentelle Eckdaten / offene Verifikationen

Development: beste Konfigurationen je Repräsentation und Selector-Familie. Alle Precision-/Recall-Spalten sind mean question-level metrics.

Representation	Selector	Parameter	Q-F1	EM	Precision	Recall
E5	Top-1 + Thresh.	$\theta = 0.83959$	0.6474	0.6366	0.6528	0.6447
E5	Relative Margin	$\gamma = 0.0025$	0.6312	0.6204	0.6366	0.6285
E5	Top-1	$k = 1$	0.6165	0.6042	0.6227	0.6134
E5	Threshold	$\theta = 0.866475$	0.4941	0.3657	0.4578	0.6285
TF-IDF	Relative Margin	$\gamma = 0.235$	0.5702	0.5579	0.5764	0.5671
TF-IDF	Top-1 + Thresh.	$\theta = 0.0999$	0.5671	0.5532	0.5741	0.5637
TF-IDF	Top-1	$k = 1$	0.5509	0.5370	0.5579	0.5475
TF-IDF	Threshold	$\theta = 0.127665$	0.4866	0.3657	0.4596	0.5706
Sentence-BERT	Top-1 + Thresh.	$\theta = 0.6751$	0.3989	0.3958	0.4005	0.3981
Sentence-BERT	Relative Margin	$\gamma = 0.005$	0.3866	0.3819	0.3889	0.3854
Sentence-BERT	Top-1	$k = 1$	0.3742	0.3681	0.3773	0.3727
Sentence-BERT	Threshold	$\theta = 0.7095375$	0.3583	0.2801	0.3343	0.4421

Frozen winner: validation and held-out test.

Split	Q-F1	EM	Prec.	Rec.	Micro F1	ZG abst.
Validation	0.6111	0.5972	0.6181	0.6076	0.6475	0.4167
Test	0.4907	0.4861	0.4931	0.4896	0.5041	0.4091

Frozen test system details: 144 submitted / 144 evaluated / 0 unanswered; average selected chunks = 0.7917; empty-selection rate = 0.2083; TP=62, FP=52, FN=70.

TODO before final Results prose: Insert verified test baselines and frozen manual-error-category counts; do not infer either from planning notes.

6 Conclusion

Leitfragen für diesen Abschnitt

- **RQ1 direkt beantworten:** E5 erzielt im evaluierten Datensatz die stärksten Development- und Validation-Ergebnisse; TF-IDF bleibt konkurrenzfähig; der evaluierte Sentence-BERT-Checkpoint ist schwächer. Keine Generalisierung über diesen Datensatz hinaus.
- **RQ2 direkt beantworten:** Representation und Selector tragen beide wesentlich zum gemessenen Verhalten bei. Der finale E5 Top-1+Threshold-Selector verbindet Ranking, Output-Cap und Abstention und ist die ausgewählte Validation-Konfiguration; daraus keine universelle Dominanz von Top-1+Threshold für jede Repräsentation ableiten.
- **RQ3 direkt beantworten:** Die eingefrorene Konfiguration generalisiert schwächer auf Test als auf Validation. Die finale Schlussfolgerung zu Fehlerursachen erst nach Freeze der manuellen Error-Analysis formulieren.
- **Praktische Implikation:** Evidence Retrieval kann als klar evaluierbare vorgelagerte Komponente für spätere QA/RAG-Systeme dienen; diese Arbeit selbst evaluiert jedoch keine generierten Antworten.

7 Limitations and Future Work

Leitfragen für diesen Abschnitt

- **Korpus- und Domäneneinschränkung:** Ein einzelnes regulatorisches Dokument / ein Studiengang; Generalisierbarkeit auf andere Prüfungsordnungen, Hochschulen oder Rechtsdokumente ist nicht gezeigt.
- **Dataset construction:** Projekt-spezifisch konstruierte Fragen und minimale Gold-Evidence-Sets; Provenance und Auditprozess müssen transparent berichtet werden. Keine Inter-Annotator-Reliability behaupten, falls keine unabhängige Doppelannotation vorliegt.
- **Hard Top-1 cap:** 10 Testfragen benötigen zwei Gold-Chunks; der finale Selector kann höchstens einen Chunk liefern und ist damit für exact full-set retrieval strukturell begrenzt.
- **Abstention calibration:** Auf Test werden nur 9 von 22 Zero-Gold-Fragen korrekt abstainiert; zugleich entstehen answerable abstentions. Das System ist daher weder einfach nur zu konservativ noch nur zu permissiv.
- **Gold-standard scope:** Das Gold Mapping bezeichnet ein minimal intended evidence set. Die finale manuelle Error-Analysis soll klären, in welchem Umfang alternative valide Evidence zu formalen Chunk-ID-Fehlern führt; bis dahin keine feste Häufigkeit behaupten.
- **Nicht evaluierte Methoden:** BM25, hybride Sparse-Dense-Verfahren, Cross-Encoder-Reranking, adaptive Multi-Chunk-Selection und generative Reader wurden nicht im eingefrorenen Vergleich getestet.
- **Future work:** adaptive Multi-Evidence-Retrieval, BM25/hybrid retrieval, Reranking, content-type-aware retrieval, breitere regulatorische Korpora, Alias-/Canonicalization-Unterstützung sowie Downstream-RAG-Evaluation nach abgeschlossenem Retrieval.

Empfohlene Quellen & Zitationszweck

- **?:** Geeigneter Literaturanker für spätere Downstream-RAG-Evaluation nach dem Retrieval-Schritt.
- **?:** Aktueller Legal-Retrieval-Kontext für robuste Retrieval-/Chunking-Fragestellungen; nicht als Beleg dafür verwenden, dass die dort vorgeschlagene Methode im vorliegenden Projekt getestet wurde.
- **?:** Benchmark-Kontext für weitere lexikalische/dichte Retrieval-Vergleiche; nicht als Primärquelle für ein konkretes hybrides Verfahren ausgeben.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- **Open issue before manuscript freeze:** final test baselines direkt verifizieren/evaluieren.
- **Open issue before manuscript freeze:** all-error-groups manual audit abschließen und Counts/Beispiele einfrieren.
- **Open issue before manuscript freeze:** Q0153–Q0160 einzeln prüfen, bevor ein kompletter Cluster-Failure-Claim erscheint.

- **Open issue before manuscript freeze:** Dataset-construction provenance und materiell relevante Software-Versionen dokumentieren.
- **Formatting:** Nach inhaltlichem Freeze in offizielles ACL-Latex-Template übertragen.