

Vergleich von Textrepräsentationen und Chunk-Selektion mit Enthaltung beim Belegstellen-Retrieval in deutschen Prüfungsordnungen

Seminarteilnehmer / Verfasser

Institut für Sprache und Information

Heinrich-Heine-Universität Düsseldorf

TODO: Universitäts-E-Mail-Adresse

Zusammenfassung

Diese Arbeit untersucht das Retrieval von Belegstellen (Chunks) in einer hierarchisch strukturierten deutschen Prüfungsordnung und berücksichtigt dabei eine explizite Enthaltungsentscheidung für Fragen, die sich aus dem Quelldokument nicht beantworten lassen. Der projektspezifische Datensatz umfasst 720 Fragen, darunter 120 absichtlich unbeantwortbare Zero-Gold-Fragen, sowie 201 Retrieval-Chunks. Verglichen werden eine sparse TF-IDF-Repräsentation und zwei feste multilinguale dichte Repräsentationen, Sentence-BERT und multilingual E5. Zusätzlich werden vier Familien von Chunk-Selektionsverfahren evaluiert: Top- k , absoluter Schwellenwert, Top- k mit absolutem Schwellenwert und Auswahl über eine relative Wertemarge. Hyperparameter werden ausschließlich auf dem Developmentset bestimmt; anschließend werden fünf Finalisten für die Validierung eingefroren und der dort ausgewählte Sieger genau einmal auf dem zurückgehaltenen Testsplit evaluiert. Die ausgewählte Konfiguration aus multilingualem E5 und Top-1 mit Schwellenwert ($\theta = 0.83959$) erreicht einen mittleren fragenweisen F1-Wert für die Chunkauswahl von 0.647 auf dem Entwicklungs-, 0.611 auf dem Validierungs- und 0.491 auf dem Testsplit. Die vollständige Prüfung der 74 nicht exakt korrekten Testfälle identifiziert 21 Abrufe ähnlicher, aber falscher Chunks, 18 schwellenwertbedingte Enthaltungen bei beantwortbaren Fragen, 13 falsch-positive Abrufe bei Zero-Gold-Fragen, 9 strukturelle Top-1-Limitationen, 9 Fälle valider alternativer Chunks und 4 Probleme der Frageformulierung bzw. Lexik. Eine im Entwicklungs- und Validierungssplit ungesehene Evidenzgruppe mit acht Testfragen führt zu acht Fällen mit F1 = 0 und verdeutlicht damit die strengere Generalisierung auf Evidenzgruppen, die durch die gegen Evidenz-Leckage abgesicherte Datenaufteilung entsteht.

1 Einleitung

Leitfragen für diesen Abschnitt

- **Problem und Geltungsbereich:** Warum ist die präzise Identifikation von Belegstellen in einer strukturierten Prüfungsordnung ein eigenständiges Problem des Informationsretrievals? Welche Rolle spielen rechtlich nahe, aber funktional unterschiedliche Passagen, Tabellen und Studienverlaufsinformationen?
- **Retrieval als vorgelagerte Komponente:** Warum wird in dieser Arbeit isoliert *Belegstellen-Retrieval* bzw. Vorhersage von Evidenzsets untersucht, statt generierte Antworten oder End-to-End-QA zu evaluieren? Wie ordnet sich Retrieval als vorgeschaltete Komponente wissensintensiver QA/RAG-Systeme ein, ohne daraus eine Garantie gegen Halluzinationen abzuleiten?
- **Enthaltung:** Warum muss das System für plausibel klingende, aber aus der Quelle nicht beantwortbare Fragen explizit [] vorhersagen können?
- **Forschungsfragen:**
 - **RQ1 – Repräsentation:** Wie unterscheiden sich spärliche lexikalische und dichte semantische Repräsentationen hinsichtlich ihrer Fähigkeit, antwortstützende Chunks aus einer deutschen Prüfungsordnung abzurufen?
 - **RQ2 – Selektion und Enthaltung:** Wie beeinflussen unterschiedliche Strategien zur Chunk-Selektion und Enthaltung die Retrieval-Leistung und das Enthaltungsverhalten?

- **RQ3 – Generalisierung und Fehlermuster:** Wie gut generalisiert die ausgewählte Konfiguration auf den zurückgehaltenen Testsplitt, und welche beobachteten Fehlermuster sowie Eigenschaften der Datenaufteilung und Evaluation stehen mit den verbleibenden Fehlern in Zusammenhang?

- **Beiträge vorsichtig einordnen:** Empirischer Vergleich der drei Repräsentationen; separater Vergleich der Selektions-/Enthaltungsregeln; projekt-spezifischer kuratierter Retrieval-Datensatz; gegen Evidenzleckage abgesichertes Evaluationsdesign; Fehleranalyse des eingefrorenen Systems. Keine Behauptung einer erstmaligen Methode, keine SOTA-Behauptung und keine allgemeine Überlegenheitsbehauptung.

Empfohlene Quellen & Zitationszweck

- **Lewis et al. (2020):** Primärquelle dafür, Retrieval als explizite nicht-parametrische Wissenskomponente in wissensintensiven NLP/QA-Systemen zu motivieren. Nicht als Beleg verwenden, dass das hier untersuchte Retrieval Halluzinationen verhindert.
- **Karpukhin et al. (2020):** Grundlegende Arbeit zum dichten Passage-Retrieval für offene domänenübergreifende QA; geeignet zur Einordnung von Bi-Encoder-Retrieval.
- **Rajpurkar et al. (2018):** Analogie für die wissenschaftliche Bedeutung unbeantwortbarer Fragen und expliziter Entscheidungen ohne Antwort.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- Gegenstand: Prüfungsordnung 2026 für den BA Computerlinguistik im untersuchten Dokumentkorpus.
- Vorhersageziel: Menge von Retrieval-Chunk-IDs; keine generierte Antwortqualität.

- Primäre Metrik: mittlerer fragenweiser F1 der Belegstellenauswahl.
- Offizieller eingefrorener Test-Endpunkt: $F1 = 0.4907$ bei 144/144 eingereichten und ausgewerteten Vorhersagedatensätzen.

[Fließtextplatzhalter für Abschnitt 1]

2 Motivation und verwandte Arbeiten

Leitfragen für diesen Abschnitt

- **Sparsames vs. dichtes Retrieval:** Welche Grundlagen des Vektorraummodells und von TF-IDF sind für den Vergleich mit neuronalen Satz-/Passage-Embeddings relevant?
- **Allgemeine semantische Ähnlichkeit vs. retrieval-orientierte Kodierung:** Welche methodische Differenz besteht zwischen einem allgemeinen multilingualen Sentence-BERT-Modell-Checkpoint und E5 als retrieval-orientierter Text-Embedding-Familie? Nur als Motivation formulieren, nicht als kausale Erklärung des Projektergebnisses.
- **Zero-Shot-Robustheit:** Was zeigt BEIR tatsächlich? Insbesondere: BM25 bleibt auf heterogenen Zero-Shot-Retrieval-Aufgaben eine starke lexikalische Vergleichsverfahren. Daraus nicht ableiten, BEIR beweise die projektspezifische Stärke von TF-IDF aufgrund administrativer Fachterminologie.
- **Selektive Vorhersage / Enthaltung:** Wie motivieren Ablehnungsoption und QA mit unbeantwortbaren Fragen das bewusste Zurückweisen unsicherer bzw. nicht belegbarer Anfragen?
- **Kontext juristischer und regulatorischer Retrieval-Aufgaben:** Welche Arbeiten zeigen, dass juristische Retrieval-Aufgaben und strukturell ähnliche Rechtsdokumente besondere Evidenz-Disambiguierung erfordern?
- **Wissenschaftliche Einordnung:** Die Arbeit als kontrollierte Fallstudie in einem kleinen deutschen regulatorischen

Korpus positionieren. Keine unbelegte Behauptung, erstmals Prüfungsordnungs-Retrieval zu untersuchen.

Empfohlene Quellen & Zitationszweck

- **Sparsames Retrieval:** Spärck Jones (1972) für Termspezifität/IDF und Salton et al. (1975) für das klassische Vektorraummodell.
- **Satz-Embeddings:** Reimers and Gurevych (2019) für Sentence-BERT sowie Reimers and Gurevych (2020) für multilinguale Distillation multilingualer Satz-Embeddings.
- **Retrieval-Embeddings:** Wang et al. (2022) und Wang et al. (2024) für die E5-Familie.
- **Benchmarks:** Thakur et al. (2021) für heterogene Zero-Shot-IR-Evaluation und die Robustheit von BM25; Muennighoff et al. (2023) für aufgabenübergreifende Embedding-Evaluation.
- **Enthaltung:** Geifman and El-Yaniv (2019) für selektive Vorhersage / Ablehnungsoption; Rajpurkar et al. (2018) für QA mit unbeantwortbaren Fragen.
- **Deutsche Rechtsdomäne:** Wrzalik and Krechel (2021) und Büttner and Habernal (2024) zur Einordnung deutscher juristischer IR-/QA-Aufgaben.
- **Aktueller Kontext für juristisches Retrieval:** Reuter et al. (2025) zeigt aktuelle Retrieval-Probleme in großen, strukturell ähnlichen juristischen Dokumentbeständen. Die Aufgabe ist nicht identisch mit dem hier untersuchten Einzelkorpus; die Quelle dient nur der Domänenpositionierung.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- Verwandte Arbeiten kompakt halten; keine breite Historie des juristischen NLP.
- TF-IDF-Erklärung im Ergebnisteil nur als *plausible Erklärung*: hohe lexikalische

Spezifität wurde nicht als Kausalmechanismus experimentell isoliert.

- Sentence-BERT nur als im vorliegenden Versuchsaufbau schwächere Repräsentation beschreiben; keine Generalisierung auf juristisches NLP insgesamt.

[Fließtextplatzhalter für Abschnitt 2]

3 Methodik

Leitfragen für diesen Abschnitt

- **Textrepräsentationen:**
 - **TF-IDF:** Tatsächlich ausgeführte Konfiguration: `TfidfVectorizer(lowercase=True, ngram_range=(1,3))`. Das Vokabular wird auf den Chunk-Texten gefittet; die Fragen werden anschließend in denselben Raum transformiert. Keine sublineare TF-Skalierung behaupten, da `sublinear_tf` nicht gesetzt wurde.
 - **Sentence-BERT:** Tatsächlich verwendeter Modell-Checkpoint: `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` (384-dimensionale Satz-Embeddings). Kein selbst implementiertes Mittelwert-Pooling behaupten; die Repräsentation wird über `SentenceTransformer` erzeugt.
 - **Multilingual E5:** Modell-Checkpoint `intfloat/multilingual-e5-base` (768 Dimensionen). Fragen werden mit `query:` und Chunks mit `passage:` präfixiert.
 - Keine der beiden dichten Repräsentationen wurde auf dem Projektkorpus feinabgestimmt.
- **Ähnlichkeitsberechnung:** Für jede Repräsentation wird Kosinusähnlichkeit zwischen allen 720 Fragen und 201 Chunks berechnet. Die resultierende Matrix hat 720×201 Einträge. Bei den neuronalen Encodern wurde `normalize_embeddings=False` ver-

wendet; daher nicht behaupten, die gespeicherten dichten Vektoren seien vorab L2-normalisiert. Die Kosinus-ähnlichkeit selbst normiert durch die Vektornormen.

- **Selektorfamilien:**

1. *Top-k*:

$$S_{\text{top-}k}(q) = \text{argtop}_k\{s(q, c_i)\}.$$

Gibt bei ausreichend großer Sammlung immer k Chunks zurück und kann allein nicht abstainieren.

2. *Absoluter Schwellenwert*:

$$S_{\theta}(q) = \{c \in \mathcal{C} \mid s(q, c) \geq \theta\}.$$

Kann $[]$ oder mehrere Chunks zurückgeben.

3. *Top-k + Schwellenwert*: Zunächst die Chunks, die den Schwellenwert überschreiten, nach Ähnlichkeitswert ordnen, dann höchstens die ersten k zurückgeben. Damit werden absolute Filterung, Enthaltung und Begrenzung der Ausgabemenge kombiniert.
4. *Relative Marge*: Mit s_k als Ähnlichkeitswert auf Rang k und s_{k+1} als folgendem Ähnlichkeitswert gilt

$$m_k(q) = \frac{s_k - s_{k+1}}{\max(|s_k|, 10^{-12})}.$$

$\text{Top-}k$ wird nur ausgegeben, wenn $m_k(q) \geq \gamma$; andernfalls wird $[]$ vorhergesagt. Für $k = 1$ misst dies die relative Trennung zwischen Rang 1 und Rang 2.

- **Suchbereiche für Schwellenwerte**: Erklären, dass repräsentationsspezifische Regionen auf dem Entwicklungssplit aus robusten Quantilen von schlechtesten Gold-Scores, besten Nicht-Gold-Scores und höchsten Zero-Gold-Scores abgeleitet wurden; die eigentliche Parametersuche wurde ausschließlich auf dem Entwicklungssplit ausgewertet.

Empfohlene Quellen & Zitationszweck

- **Salton et al. (1975)**: Vektorraumdarstellung und Cosine-Ähnlichkeit als klassische IR-Grundlage.
- **Reimers and Gurevych (2019), Reimers and Gurevych (2020)**: Sentence-BERT und multilinguale Satz-Embeddings.
- **Wang et al. (2022), Wang et al. (2024)**: Retrieval-orientiertes E5-Training und multilingualer E5-Kontext.
- **Geifman and El-Yaniv (2019)**: Konzeptionelle Grundlage für selektive Vorhersage; die konkrete Ähnlichkeits-Schwellenwertregel bleibt eine Designentscheidung dieses Experiments.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- Eingefrorener Vergleich im Paper: TF-IDF, Sentence-BERT, E5; Kosinusähnlichkeit; Top- k , Schwellenwert, Top- k +Schwellenwert, Relative Marge.
- Nicht in die Argumentation aufnehmen: im Code zusätzlich vorhandene Skalarprodukt-/euklidische Funktionen oder softmax_cumulative, da sie nicht zu den eingefrorenen vier Selektorfamilien des Papers gehören.
- Dokumentierte anfängliche Suchbereiche für Schwellenwerte: E5 0.8331–0.8865; TF-IDF 0.0591–0.5162; Sentence-BERT 0.4740–0.7595.

[Fließtextplatzhalter für Abschnitt 3]

4 Experimenteller Aufbau

Leitfragen für diesen Abschnitt

- **Korpus und Chunking**:
 - Wie wurden die 201 aktiven Retrieval-Chunks aus allgemeiner Prüfungsordnung, fachspezifischem Anhang, exemplarischem Studienverlaufsplan und Vorspann gebildet?
 - Welche Kontextüberschriften sorgen dafür, dass kurze Tabellen-

/Anhangswerte außerhalb ihrer Originalseite interpretierbar bleiben?

- Welche finalen Qualitätschecks bestanden die Chunks (eindeutige IDs, keine leeren Chunks, vollständige Quellreihenfolge)?

- **Frage- und Goldstandard-Konstruktion:**

- 720 Fragen insgesamt: 600 beantwortbare und 120 Zero-Gold-Fragen.
- Gold-Ziel ist `all_required_chunk_ids`: ein *minimal vorgesehenes vollständiges Evidenzset*, nicht notwendigerweise die vollständige Menge aller semantisch gültigen Alternativbelege.
- **TODO – Provenienz einfrieren:** Vor finaler Prosa exakt dokumentieren, welche Schritte bei Chunking, Fragerstellung, Zuordnung und Prüfung menschlich, skriptgestützt bzw. ggf. sprachmodellassistent waren. Keine unbelegte Darstellung als vollständig manuell oder vollständig LLM-generiert verwenden.

- **Gegen Evidenzleckage abgesicherte Datenaufteilung:**

- Entwicklung/Validierung/Test: 432/144/144 Fragen.
- Gruppierungsregel `same_non_empty_gold_chunk_set`: Fragen mit identischem nicht-leerem Gold-Evidenzset bleiben im selben Datenanteil.
- Integrität der Datenaufteilung: 315 Gruppen; größte Gruppe 13 Fragen; keine nicht-leere Gold-Set-Gruppe in mehreren Datenanteilen vorkommt; Zero-Gold-Fragen bilden jeweils Einzelgruppen.
- Abwägung: weniger Evidenz-Leakage, dafür strengere Generalisierung auf vollständig ungesehene Evidenzgruppen.

- **Selektionsprotokoll:**

- Selektor-/Hyperparameterentwicklung nur auf dem Entwicklungssplit.
- Ranking: mittlerer fragenweiser F1; dokumentierte Regeln bei Gleichstand: exakte Übereinstimmung, Präzision, dann weniger ausgewählte Chunks.
- Fünf Finalisten vor Validierung einfrieren; keine Nachjustierungsschleife nach der Validierung; einen Sieger auf dem Validierungssplit einfrieren; genau diesen einmal auf dem Testsplit evaluieren.

- **Evaluation:**

- `Gold = []` und `Pred = []` ergibt Präzision=Recall=F1=1 und exakte Übereinstimmung.
- `Gold = [], Pred ≠ []` sowie `Gold ≠ [], Pred = []` ergeben pro Frage F1=0.
- Ein komplett fehlender Vorhersagedatensatz ist semantisch anders als ein explizites `[]`: fehlende Datensätze werden aus den Mittelwerten ausgeschlossen und als unbeantwortet gezählt. Die eingefrorene Testauswertung weist 144/144 erreicht/ausgewertet und 0 unbeantwortet aus.
- Sekundäre Metriken: mittlere fragenweise Präzision/Recall, exakte Übereinstimmung, Micro-F1, Zero-Gold-Enthaltungsrate, Rate leerer Selektionen, durchschnittliche Anzahl ausgewählter Chunks.

- **Vergleichsverfahren:**

- *Zufälliges Top-1*: gleichverteilt zufälliger Chunk; 100 feste Zufalls-Seeds 0–99; Mittelwert $\pm$ Standardabweichung berichten.
- *Häufigste Entwicklungsantwort*: häufigstes nicht-leeres exaktes Gold-Set auf dem Entwicklungssplit einmal einfrieren und für Validierung/Test konstant vorhersagen.
- *Immer keine Auswahl*: für jede Frage `[]`.

- Autoritative Vergleichsverfahren auf dem Testsplit sind jetzt eingefroren: Zufälliges Top-1 (100 Zufalls-Seeds) erreicht mittleren Q-F1 0.0047 ± 0.0049 ; Häufigste Entwicklungsantwort erreicht Q-F1 0; Immer keine Auswahl erreicht Q-F1 0.1528 und entspricht damit genau dem Anteil der 22 Zero-Gold-Fragen im 144-Fragen-Testsplit. Die vollständigen Werte stehen in der Ergebnis-Faktenbox.

Empfohlene Quellen & Zitationszweck

- **Rajpurkar et al. (2018)**: Literaturkontext für bewusst unbeantwortbare Fragen; die konkrete Zero-Gold-Konstruktion ist projektspezifisch.
- **Muennighoff et al. (2023)**: Kontext für standardisierte Embedding-/Retrieval-Evaluation; die konkrete mittlere Set-F1-Definition des Projekts muss dennoch selbst explizit definiert werden.

Verbindliche experimentelle Eckdaten / offene Verifikationen

Verifizierte Verteilung der Gold-Sets.

Split	Gesamt	Zero-Gold	1-Gold	2-Gold
Entwicklung	432	74	340	18
Validierung	144	24	116	4
Test	144	22	112	10
Gesamt	720	120	568	32

- 201 aktive Retrieval-Chunks; 10,194 Wörter; mittlere Chunklänge 50.72 Wörter; Median 41; Spannweite 8–204 Wörter.
- Verteilung der Quellschichten aus dem Qualitätsaudit: 133 Allgemeine Prüfungsordnung, 36 Exemplarischer Studienverlaufsplan, 30 Fachspezifischer Anhang, 2 Vorspann.
- Die Chunk-Sammlung ist als `ready_with_minor_issues` auditiert; dokumentierte kleinere Quell-/Formatrisiken nicht als fehlerhafte Vorverarbeitung darstellen.
- **Eingefrorene Reproduzierbarkeitsumgebung**: Projektprotokolle verwenden

Python 3.11; der gepinnte PyTorch-Paket ist ebenfalls für CPython 3.11 (cp311). Materiell relevante Bibliotheksversionen aus `requirements.txt`:
`scikit-learn==1.9.0,`
`sentence-transformers==3.4.1,`
`transformers==4.46.3,`
`torch==2.1.2` (CPU-Build),
`numpy==1.26.4,` `scipy==1.17.1,`
`pandas==3.0.5,` `tokenizers==0.20.3`
und `huggingface-hub==0.36.2`. In der finalen Prosa genügen die für Reproduzierbarkeit relevanten Kernpakete; die komplette Abhängigkeitsliste bleibt im Projektartefakt `requirements.txt`.

[Fließtextplatzhalter für Abschnitt 4]

5 Ergebnisse und Evaluation

Leitfragen für diesen Abschnitt

• RQ1 – Vergleich der Repräsentationen:

- E5 erreicht auf dem Entwicklungssplit die stärksten Werte unter den evaluierten Repräsentationen.
- TF-IDF bleibt in diesem Korpus konkurrenzfähig. Zulässige Interpretation: Die hohe lexikalische Spezifität des Korpus ist eine plausible Erklärung; sie wurde nicht als Kausalmechanismus isoliert gemessen.
- Der evaluierte multilingual MiniLM Sentence-BERT-Modell-Checkpoint liegt im betrachteten Versuchsaufbau hinter E5 und TF-IDF. Keine Generalisierung wie “Sentence-BERT funktioniert nicht für Rechtstexte”.

• RQ2 – Selektor und Enthaltung:

- Nicht nach einem universell “überlegenen” Selektor fragen, sondern nach Abwägungen zwischen Belegstellen-Retrieval, Begrenzung der Ausgabemenge und Enthaltung.
- Reines Top-1 ist stark, kann aber nie abstainieren. Reiner Schwellenwert kann abstainieren, kann jedoch viele Chunks selektieren und dadurch Präzision verlieren.

- Top-1 + absoluter Schwellenwert erzeugt die stärkste E5-Konfiguration auf dem Entwicklungssplit und bleibt der Sieger auf dem Validierungssplit; Relative Marge ist konkurrenzfähig, insbesondere für E5/TF-IDF, aber nicht der finale Sieger auf dem Validierungssplit.
- Wichtig: Für TF-IDF ist Relative Marge auf dem Entwicklungssplit geringfügig stärker als Top-1+Schwellenwert; daher keine universelle Selektor-Rangordnung behaupten.

• **Validierung und eingefrorene Modellauswahl:**

- E5 + Top-1 + Schwellenwert 0.83959: $F1 = 0.6111$, $EM = 0.5972$, mittlere Präzision = 0.6181, mittlerer Recall = 0.6076, Zero-Gold-Enthaltungsrate = 0.4167.
- Nur die fünf eingefrorenen Finalisten wurden auf dem Validierungssplit verglichen; Sentence-BERT war nicht unter diesen fünf Finalisten. Daher Validierung nicht als erneuten vollständigen Drei-Repräsentationen-Vergleich formulieren.

• **RQ3 – Zurückgehaltener Testsplit:**

- Offizieller Test: $F1 = 0.4907$, $EM = 0.4861$, mittlere Präzision = 0.4931, mittlerer Recall = 0.4896, Micro-F1 = 0.5041.
- Rate leerer Selektionen = 0.2083; Zero-Gold-Enthaltung = $9/22 = 0.4091$. Das System zeigt sowohl falsche Enthaltungen bzw. zu geringe Retrieval-Ausgabe als auch falsch-positive Abrufe bei Zero-Gold.
- Rückgang von Validierung zu Test: ca. 0.1204. Keine Aussage, dieser Rückgang sei “innerhalb einer normalen Standardabweichung”, solange keine entsprechende Unsicherheitsanalyse durchgeführt wurde.

• **Fehleranalyse:**

1. *Strukturelle Limitation bei mehreren Belegstellen:* Bei echten 2-Gold-Fragen kann ein Top-1-System nie eine exakte Übereinstimmung des vollständigen Sets erzielen. Wenn genau einer der zwei Gold-Chunks korrekt geliefert wird, ist maximal $P = 1$, $R = 0.5$, $F1 = 2/3$. Im Test gibt es 10 2-Gold-Fragen.
2. *Enthaltungen bei beantwortbaren Fragen vs. falsch-positive Abrufe bei Zero-Gold* getrennt quantifizieren.
3. *Fall einer ungesesehenen Evidenzgruppe:* Gruppe G0040 umfasst acht Testfragen Q0153–Q0160 mit demselben Gold-Chunk P025CL-GEN-C03-P12-A02; dieses nicht-leere Gold-Set kommt in Entwicklung und Validierung nicht vor. Alle acht Fragen erzielen auf dem Testsplit $F1 = 0$: Q0153, Q0154, Q0155, Q0156, Q0158 und Q0159 liefern jeweils einen falschen nicht-leeren Chunk; Q0157 und Q0160 abstainieren mit []. Der Cluster ist daher ein verifiziertes Beispiel für Generalisierungsfehler auf Evidenzgruppen, nicht für einen fehlerhaften Testsplit.
4. *Strenge des Goldstandards:* Die abgeschlossene Prüfung falscher Chunks klassifiziert 9 formal falsche Chunk-ID-Vorhersagen als `valid_alternative_evidence`. Diese Fälle zeigen, dass das minimal vorgesehene Gold-Set nicht jede semantisch vollständig ausreichende Alternativstelle enthält; der offizielle Wert bleibt unverändert.
5. *Vollständige Fehlerprüfung:* Die 31 Fälle mit falscher nicht-leerer Vorhersage und 43 strukturellen bzw. enthaltungsbezogenen Fälle decken zusammen alle 74 nicht exakt korrekten Testfragen ab. Finale Kategorien: 21 ähnliche, aber falsche Chunks, 18 schwellenwertbedingte Enthaltungsfehler, 13 falsch-positive Abrufe bei unbeantwortbaren Fragen, 9 strukturelle Top-1-

Limitationen, 9 Fälle valider alternativer Belegstellen und 4 Probleme der Frageformulierung bzw. Lexik.

6. *Post-hoc-Diagnose (optional)*: Da nun sowohl die 9 Fälle mit valider alternativer Evidenz als auch alle acht Fälle mit $F1 = 0$ der G0040-Gruppe verifiziert sind, kann eine klar als Sensitivitätsrechnung bezeichnete Variante berechnet werden:

$$\frac{70.6667 + 9}{144 - 8} \approx 0.5858.$$

Dieser Wert ist *kein* korrigierter Testwert und darf nicht in die Hauptresultattabelle eingehen; er zeigt lediglich, wie stark diese beiden identifizierten Daten-/Evaluationsphänomene den rohen Leistungsabstand beeinflussen können.

- **Vergleich mit Vergleichsverfahren**: Die eingefrorenen Vergleichsverfahren auf dem Testsplit sind verifiziert und werden in der Ergebnis-Faktenbox berichtet.

Empfohlene Quellen & Zitationszweck

- **Thakur et al. (2021)**: Nur zur allgemeinen Einordnung starker lexikalischer Zero-Shot-Vergleichsverfahren; nicht als Beweis der projektspezifischen TF-IDF-Ursache.
- **Reuter et al. (2025)**: Aktueller Domänenkontext dafür, dass Retrieval in strukturell ähnlichen juristischen Beständen fehleranfällig sein kann; keine direkte Erklärung einzelner Projektfehler.
- **Eigene eingefrorene Evaluation**: Alle Zahlen und Fehleranzahlen aus Projektarbefakten berichten; Literatur darf diese Messergebnisse nicht ersetzen.

Verbindliche experimentelle Eckdaten / offene Verifikationen

Entwicklung: beste Konfigurationen je Repräsentation und Selektor-Familie. Alle Präzisions-/Recall-Spalten enthalten mittlere

fragenweise Metriken.

Repräsentation	Selektor	Parameter	Q-F1	EM	Präzision	Recall
E5	Top-1 + Schwelle	$\theta = 0.83959$	0.6474	0.6366	0.6528	0.6447
E5	Relative Marge	$\gamma = 0.0025$	0.6312	0.6204	0.6366	0.6285
E5	Top-1	$k = 1$	0.6165	0.6042	0.6227	0.6134
E5	Schwellenwert	$\theta = 0.866475$	0.4941	0.3657	0.4578	0.6285
TF-IDF	Relative Marge	$\gamma = 0.235$	0.5702	0.5579	0.5764	0.5671
TF-IDF	Top-1 + Schwelle	$\theta = 0.0999$	0.5671	0.5532	0.5741	0.5637
TF-IDF	Top-1	$k = 1$	0.5509	0.5370	0.5579	0.5475
TF-IDF	Schwellenwert	$\theta = 0.127665$	0.4866	0.3657	0.4596	0.5706
Sentence-BERT	Top-1 + Schwelle	$\theta = 0.6751$	0.3989	0.3958	0.4005	0.3981
Sentence-BERT	Relative Marge	$\gamma = 0.005$	0.3866	0.3819	0.3889	0.3854
Sentence-BERT	Top-1	$k = 1$	0.3742	0.3681	0.3773	0.3727
Sentence-BERT	Schwellenwert	$\theta = 0.7095375$	0.3583	0.2801	0.3343	0.4421

Eingefrorener Sieger: Validierung und zurückgehaltener Test.

Split	Q-F1	EM	Präz.	Rec.	Micro-F1	ZG-EM
Validierung	0.6111	0.5972	0.6181	0.6076	0.6475	0.41
Test	0.4907	0.4861	0.4931	0.4896	0.5041	0.40

Eingefrorene Details des Testsystems: 144 eingereicht / 144 ausgewertet / 0 unbeantwortet; durchschnittliche Anzahl ausgewählter Chunks = 0.7917; Rate leerer Selektionen = 0.2083; TP=62, FP=52, FN=70.

Zurückgehaltenes Testsystem im Vergleich zu den eingefrorenen Vergleichsverfahren. Für Zufälliges Top-1 werden Mittelwert $\pm$ Standardabweichung über 100 feste Zufalls-Seeds berichtet.

System	Q-F1	Präz.
Zufälliges Top-1	0.0047 ± 0.0049	0.0050 ± 0.0050
Häufigste Entwicklungsantwort	0.0000	0.0000
Immer keine Auswahl	0.1528	0.1528
E5 Top-1 + Schwellenwert	0.4907	0.4931

Eingefrorene Kategorisierung aller 74 nicht exakt korrekten Testfälle.

Fehlerkategorie	Anzahl	Anteil an n
Ähnlicher, aber falscher Chunk	21	
Schwellenwertbedingte Fehl-Enthaltung	18	
Falsch-positiver Abruf bei unbeantwortbarer Frage	13	
Strukturelle Top-1-Limitation	9	
Valide alternative Belegstelle	9	
Frageformulierung / lexikalisches Problem	4	
Gesamt	74	

[Fließtextplatzhalter für Abschnitt 5]

6 Fazit

Leitfragen für diesen Abschnitt

- **RQ1 direkt beantworten**: E5 erzielt im evaluierten Datensatz die stärksten Ergebnisse auf Entwicklungs- und Validierungssplit; TF-IDF bleibt konkurrenzfähig; der evaluierte Sentence-BERT-Modell-Checkpoint ist schwächer. Keine Generalisierung über diesen Datensatz

hinaus.

- **RQ2 direkt beantworten:** Repräsentation und Selektor tragen beide wesentlich zum gemessenen Verhalten bei. Der finale E5 Top-1+Schwellenwert-Selektor verbindet Ranking, Ausgabegrenze und Enthaltung und ist die auf dem Validierungssplit ausgewählte Konfiguration; daraus keine universelle Dominanz von Top-1+Schwellenwert für jede Repräsentation ableiten.
- **RQ3 direkt beantworten:** Die eingefrorene Konfiguration generalisiert schwächer auf dem Testsplit als auf dem Validierungssplit. Die vollständige Auditierung der 74 nicht exakt korrekten Fälle zeigt mehrere gleichzeitig wirksame Fehlermuster: Abruf falscher Chunks, schwellenwertbedingte Enthaltung, falsch-positiver Abruf bei Zero-Gold, die strukturelle Top-1-Grenze, valide alternative Belegstelle sowie Frageformulierungsprobleme. Die acht Fälle mit $F1 = 0$ der ungesesehenen Evidenzgruppe G0040 sind ein besonders deutliches Beispiel für die strengere Generalisierung auf Evidenzgruppen.
- **Praktische Implikation:** Belegstellen-Retrieval kann als klar evaluierbare vorgelegte Komponente für spätere QA/RAG-Systeme dienen; diese Arbeit selbst evaluiert jedoch keine generierten Antworten.

[Fließtextplatzhalter für Abschnitt 6]

7 Limitationen und Ausblick

Leitfragen für diesen Abschnitt

- **Korpus- und Domäneneinschränkung:** Ein einzelnes regulatorisches Dokument / ein Studiengang; Generalisierbarkeit auf andere Prüfungsordnungen, Hochschulen oder Rechtsdokumente ist nicht gezeigt.
- **Datensatzerstellung:** Projekt-spezifisch konstruierte Fragen und minimale Gold-Evidenzsets; Provenienz und Prüfprozess müssen transparent berichtet werden. Keine Inter-Annotator-Reliabilität behaupten,

falls keine unabhängige Doppelannotation vorliegt.

- **Harte Top-1-Begrenzung:** 10 Testfragen benötigen zwei Gold-Chunks; der finale Selektor kann höchstens einen Chunk liefern und ist damit für exaktes Retrieval des vollständigen Sets strukturell begrenzt.
- **Kalibrierung der Enthaltung:** Auf Test werden nur 9 von 22 Zero-Gold-Fragen korrekt abstainiert; zugleich entstehen Enthaltungen bei beantwortbaren Fragen. Das System ist daher weder einfach nur zu konservativ noch nur zu freizügig.
- **Geltungsbereich des Goldstandards:** Das Gold-Mapping bezeichnet ein minimal vorgesehenes Evidenzset. Die finale Prüfung falscher Chunks identifiziert 9 Fälle, in denen eine formal falsche Chunk-ID dennoch voll ausreichende alternative Belegstelle liefert. Das ist eine Limitation der Exhaustivität des Goldstandards, nicht ein Grund, den offiziellen Testwert nachträglich zu ersetzen.
- **Nicht evaluierte Methoden:** BM25, hybride Sparse-Dense-Verfahren, Cross-Encoder-Reranking, adaptive Auswahl mehrerer Chunks und generative Lesemodelle wurden nicht im eingefrorenen Vergleich getestet.
- **Weiterführende Arbeiten:** adaptives Retrieval mehrerer Belegstellen, BM25/hybrides Retrieval, Reranking, inhaltstypbewusstes Retrieval, breitere regulatorische Korpora, Alias-/Kanonisierungsunterstützung sowie nachgelagerte RAG-Evaluation nach abgeschlossenem Retrieval.

Empfohlene Quellen & Zitationszweck

- **Lewis et al. (2020):** Geeigneter Literaturanker für spätere nachgelagerte RAG-Evaluation nach dem Retrieval-Schritt.
- **Reuter et al. (2025):** Aktueller Kontext für juristisches Retrieval für robuste Retrieval-/Chunking-Fragestellungen;

nicht als Beleg dafür verwenden, dass die dort vorgeschlagene Methode im vorliegenden Projekt getestet wurde.

- **Thakur et al. (2021):** Benchmark-Kontext für weitere lexikalische/dichte Retrieval-Vergleiche; nicht als Primärquelle für ein konkretes hybrides Verfahren ausgeben.

Verbindliche experimentelle Eckdaten / offene Verifikationen

- **Offener Punkt vor dem Einfrieren des Manuskripts:** Die Provenienz der Datensatzerstellung als transparenten Absatz ergänzen.

[Fließtextplatzhalter für Abschnitt 7]

Literaturverzeichnis

- Marius Büttner and Ivan Habernal. 2024. [Answering legal questions from laymen in German civil law system](#). In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2015–2027. Association for Computational Linguistics.
- Yonatan Geifman and Ran El-Yaniv. 2019. [SelectiveNet: A deep neural network with an integrated reject option](#). In *Proceedings of the 36th International Conference on Machine Learning*, volume 97 of *Proceedings of Machine Learning Research*, pages 2151–2159. PMLR.
- Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. 2020. [Dense passage retrieval for open-domain question answering](#). In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781. Association for Computational Linguistics.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. 2020. [Retrieval-augmented generation for knowledge-intensive NLP tasks](#). In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- Niklas Muennighoff, Nouamane Tazi, Loic Magne, and Nils Reimers. 2023. [MTEB: Massive text embedding benchmark](#). In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2014–2037. Association for Computational Linguistics.
- Pranav Rajpurkar, Robin Jia, and Percy Liang. 2018. [Know what you don’t know: Unanswerable questions for SQuAD](#). In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 784–789. Association for Computational Linguistics.
- Nils Reimers and Iryna Gurevych. 2019. [Sentence-BERT: Sentence embeddings using siamese BERT-networks](#). In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992. Association for Computational Linguistics.
- Nils Reimers and Iryna Gurevych. 2020. [Making monolingual sentence embeddings multilingual using knowledge distillation](#). In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4512–4525. Association for Computational Linguistics.
- Markus Reuter, Tobias Lingenberg, Ruta Liepina, Francesca Lagioia, Marco Lippi, Giovanni Sartor, Andrea Passerini, and Burcu Sayin. 2025. [Towards reliable retrieval in RAG systems for large legal datasets](#). In *Proceedings of the Natural Legal Language Processing Workshop 2025*, pages 17–30. Association for Computational Linguistics.
- Gerard Salton, Anita Wong, and Chung-Shu Yang. 1975. [A vector space model for automatic indexing](#). *Communications of the ACM*, 18(11):613–620.
- Karen Spärck Jones. 1972. [A statistical interpretation of term specificity and its application in retrieval](#). *Journal of Documentation*, 28(1):11–21.
- Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. 2021. BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*.
- Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. 2022. [Text embeddings by weakly-supervised contrastive pre-training](#). *arXiv preprint arXiv:2212.03533*.
- Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. 2024. [Multilingual E5 text embeddings: A technical report](#). Technical Report MSR-TR-2024-45, Microsoft Research.
- Marco Wrzalik and Dirk Krechel. 2021. [GerDaLIR: A German dataset for legal information retrieval](#). In *Proceedings of the Natural Legal Language Processing Workshop 2021*, pages 123–128. Association for Computational Linguistics.