

Evidence Retrieval und Chunk-Selektion mit Enthaltung

über einer deutschen Prüfungsordnung

Empirischer Vergleich lexikalischer und dichter Textrepräsentationen
unter Schwellenwert- und Margenselektion

Seminarteilnehmer / Verfasser
Institut für Sprache und Information
Heinrich-Heine-Universität Düsseldorf

August 30, 2026

Abstract

Konzeptueller Abstract (Blueprint): In dieser Arbeit wird untersucht, wie präzise administrative Belegstellen (*Evidence Chunks*) aus einer hierarchisch strukturierten deutschen Prüfungsordnung automatisiert identifiziert werden können und wie verlässlich sich ein System bei unbeantwortbaren Anfragen enthält (*Abstention*). Auf einem eigens erstellten Datensatz von 720 Fragen (davon 120 absichtlich unbeantwortbare Zero-Gold-Fragen) über 201 Chunks der Prüfungsordnung (BA Computerlinguistik, HHU Düsseldorf) werden drei Textrepräsentationen verglichen: sparse TF-IDF (1–3 Wort-N-Gramme), Sentence-BERT sowie Multilingual E5 mit asymmetrischen Aufgaben-Präfixen. Diese Repräsentationen interagieren mit vier Selektionsfamilien (Top- k , absoluter Schwellenwert, Top- k + Schwellenwert, relative Marge). Der auf dem Development-Split ermittelte Gesamtsieger (Multilingual E5 in Kombination mit Top-1 und einem Schwellenwert von $\theta = 0,8396$) erzielt einen Development-F1 von 0,647, bestätigt sich auf dem Validation-Split mit F1 = 0,611 und erreicht auf dem ungesesehenen Test-Split F1 = 0,491. Die detaillierte Fehleranalyse zeigt, dass dieser Generalization Gap maßgeblich durch strukturelle Obergrenzen bei Multi-Chunk-Fragen, ungesehene Evidenz-Subkorpora (insb. Zugangsprüfung) sowie strenge Gold-Standard-Kriterien bedingt ist.

1 Einleitung (Introduction)

Leitfragen für diesen Abschnitt

- **Problemstellung:** Warum stellt die automatisierte Beantwortung von Fragen zu Hochschul-Prüfungsordnungen besondere Herausforderungen an NLP-Systeme (komplexe Hierarchie, hohe Dichte an Rechtsbegriffen, Tabellen und Studienverlaufspläne)?
- **Retrieval als Schutzschicht:** Warum wird in dieser Arbeit isoliert das *Evidence Retrieval* (die Identifikation minimaler Beleg-Chunks) evaluiert statt einer End-to-End-Antwortgenerierung? Warum ist präzises Retrieval eine unverzichtbare Voraussetzung, um Halluzinationen vorzubeugen?
- **Enthaltung (Abstention):** Warum dürfen administrative Auskunftssysteme bei fehlender Belegstelle nicht raten, sondern müssen sich gezielt enthalten (*Selective Prediction* / *Zero-Gold*)?

- **Forschungsfragen (RQs):** Welche drei Kernfragen leiten die empirische Untersuchung?
 - **RQ1 (Repräsentation):** Wie schneidet lexikalisches Sparse-Retrieval (TF-IDF) im Vergleich zu semantischen Bi-Encodern (SBERT, E5) ab?
 - **RQ2 (Selektion & Enthaltung):** Welche Selektionsstrategie balanciert Präzision, Vollständigkeit und die Erkennung unbeantwortbarer Fragen optimal?
 - **RQ3 (Generalisierung & Fehler):** Welche strukturellen und korpusbedingten Ursachen erklären den Leistungsabfall zwischen Validierungs- und Test-Split?
- **Wissenschaftliche Transparenz:** Warum wird das finale Testergebnis (Test-F1 = 0,491) bereits in der Einleitung offen benannt, statt den Generalization Gap zu verschleiern?

Empfohlene Quellen & Zitationszweck

- **Karpukhin et al. [2020] (DPR):** Zur Motivation, dass dichtes Passage-Retrieval die entscheidende vorgeschaltete Filterstufe für verlässliche QA- und RAG-Pipelines darstellt.
- **Rajpurkar et al. [2018] (SQuAD 2.0):** Grundlegende Arbeit zur Notwendigkeit, dass Systeme erkennen müssen, was sie *nicht* wissen (unbeantwortbare Fragen / plausible Distraktoren).

Verbindliche experimentelle Eckdaten (Handover-Protokoll)

- Gegenstand: Prüfungsordnung 2026, BA Computerlinguistik, Heinrich-Heine-Universität Düsseldorf.
- Keine End-to-End-Generierung, sondern striktes Evidence Retrieval.
- Primäre Metrik: Mittlerer fragenbasierter F1-Score (Evidence-Selection F1).

2 Motivation und verwandte Arbeiten (Motivation & Related Work)

Leitfragen für diesen Abschnitt

- **Sparse vs. Dense Retrieval:** Was sind die mathematischen und konzeptionellen Grundlagen des klassischen Vektorraummodells und TF-IDF gegenüber modernen neuronalen Satz-Embeddings?
- **Satz-Embeddings vs. Retrieval-Optimierung:** Warum genügen allgemeine Modelle für semantische Textähnlichkeit (STS wie SBERT) oft nicht für asymmetrisches Frage-Dokument-Retrieval, und wie adressieren Bi-Encoder mit kontrastivem Vortraining (E5) diesen Unterschied?
- **Zero-Shot-Retrieval in Fachdomänen:** Warum zeigen Standard-Benchmarks wie BEIR, dass Sparse-Verfahren (BM25/TF-IDF) bei spezifischer Fachterminologie oft überraschend schwer zu schlagen sind?
- **Selektive Vorhersage & Enthaltung:** Wie wird die Entscheidung zur Enthaltung

tung (*Reject Option*) formuliert, um Fehlerrisiken bei niedriger Systemkonfidenz zu minimieren?

- **Deutscher Rechts- und Verwaltungskontext:** Welche spezifischen Herausforderungen dokumentiert die aktuelle Literatur bezüglich laiensprachlicher Anfragen gegenüber deutscher Rechtssprache?

Empfohlene Quellen & Zitationszweck

- **Sparse Retrieval:** Spärck Jones [1972] (statistische Termspezifität, IDF-Konzept) sowie Salton et al. [1975] (klassisches Vektorraummodell).
- **Dense Sentence Embeddings:** Reimers and Gurevych [2019] (Sentence-BERT Siamesische Netzwerke) und Reimers and Gurevych [2020] (Cross-linguale Wissensdestillation für Multilingualität).
- **Retrieval-Bi-Encoder:** Wang et al. [2022] (E5-Kontrastivtraining) und Wang et al. [2024] (Multilingual E5 technischer Bericht).
- **IR-Benchmarks:** Thakur et al. [2021] (BEIR: Robustheit lexikalischer Modelle im Zero-Shot-Szenario) und Muennighoff et al. [2023] (MTEB: Asymmetrisches Retrieval vs. symmetrische Ähnlichkeit).
- **Selective Prediction / Abstention:** Geifman and El-Yaniv [2019] (SelectiveNet: Formale Begründung der Reject Option) und Rajpurkar et al. [2018] (SQuAD 2.0).
- **Deutsche Rechtsdomäne:** Wrzalik and Krechel [2021] (GerDaLIR: Legal IR auf Deutsch) und Büttner and Habernal [2024] (GerLayQA: Diskrepanz zwischen Laienfragen und BGB-Gesetzestexten).

Verbindliche experimentelle Eckdaten (Handover-Protokoll)

- Umfang: Kompakt halten (ca. 0,6–0,8 Seiten); kein breiter Survey, sondern gezielte Begründung der Modellwahl.
- Ziel: Begründen, warum TF-IDF, SBERT und E5 ausgewählt wurden und warum Schwellenwert-Enthaltung implementiert wurde.

3 Methodik (Methodology)

Leitfragen für diesen Abschnitt

- **Mathematische Definition der Repräsentationen:**
 - *TF-IDF:* Wie werden N-Gramme (1–3 Wörter), Sublinear TF-Skalierung und IDF formal im Vektorraum aufgestellt?
 - *Sentence-BERT:* Welcher Checkpoint (`paraphrase-multilingual-mpnet-base-v2`) wurde verwendet, und wie werden Satz-Vektoren via Mean-Pooling generiert?
 - *Multilingual E5:* Welcher Checkpoint (`intfloat/multilingual-e5-base`) kam zum Einsatz? Wie brechen die Aufgaben-Präfixe `query:` und `passage:` die Symmetrie für asymmetrisches Retrieval?
- **Ähnlichkeitsmaß:** Warum wird einheitlich die Cosine Similarity $\cos(\vec{q}, \vec{c})$ auf L2-

normalisierten Vektoren über der gesamten Matrix (720×201) berechnet?

- **Formale Definition der Selektorfamilien:**

1. *Top-k*: $S_{\text{top-}k}(q) = \text{argtop}_k\{\cos(\vec{q}, \vec{c}_i)\}$. (Eigenschaft: Kann sich niemals enthalten).
2. *Absoluter Schwellenwert (Threshold)*: $S_\theta(q) = \{c \in \mathcal{C} \mid \cos(\vec{q}, \vec{c}) \geq \theta\}$. (Eigenschaft: Kann sich enthalten, aber auch beliebig viele Chunks selektieren).
3. *Top-k + Schwellenwert*: $S_{k,\theta}(q) = \{c \in \text{argtop}_k\{\cos(\vec{q}, \vec{c})\} \mid \cos(\vec{q}, \vec{c}) \geq \theta\}$. (Eigenschaft: Kombiniert Ranganalyse, Größenkontrolle und Enthaltung).
4. *Relative Marge (Relative Margin)*: Enthaltung bei unzureichendem Abstand zwischen Rang 1 und Rang 2: $(\text{Score}_1 - \text{Score}_2)/\text{Score}_1 < \gamma$.

Empfohlene Quellen & Zitationszweck

- **Salton et al. [1975]**: Vektorraum-Repräsentation und Cosine-Similarity.
- **Reimers and Gurevych [2019]**: Siamesische Transformer-Architektur.
- **Wang et al. [2024]**: Multilingual E5 Architektur und asymmetrische Präfix-Struktur.
- **Geifman and El-Yaniv [2019]**: Mathematische Fundierung von Entscheidungsregeln mit Enthaltungsoption.

Verbindliche experimentelle Eckdaten (Handover-Protokoll)

- Keine Dot-Product- oder Euklid-Ergebnisse im Hauptteil berichten (im Experiment wurde einheitlich Cosine Similarity verwendet).
- Reines Methodenkapitel: Keine chronologische Projektentwicklung schildern, sondern die mathematisch-technischen Definitionen.

4 Experimenteller Aufbau (Experimental Setup)

Leitfragen für diesen Abschnitt

- **Korpus & Chunking-Strategie:**
 - Wie ist die Prüfungsordnung (PO 2026 BA CL, HHU Düsseldorf) strukturiert?
 - Wie verteilen sich die 201 Chunks über die 4 Quellebenen (*General Regulation, Program-specific Appendix, Exemplary Study Plan, Front Matter*)?
 - Wie wurden kurze, isolierte Tabellenzellen (z.B. „keine Angabe“ oder PBB-Zuordnungen) durch standardisierte Kontext-Header eigenständig suchbar gemacht?
- **Fragendatensatz & Zero-Gold-Distraktoren:**
 - Wie setzen sich die 720 Fragen zusammen (600 beantwortbare Fragen mit minimalem Gold-Evidence-Set, 120 absichtlich unbeantwortbare Zero-Gold-Fragen mit Vorhersageziel [])?
 - Wie verteilen sich 1-Gold-Fragen (568) und 2-Gold-Fragen (32)?

- **Leakage-aware Data Split:**

- Wie wurden die Daten aufgeteilt (432 Dev / 144 Val / 144 Test)?
- Warum war die Gruppierung nach identischen Gold-Chunk-Sets zwingend notwendig, um Informationslecks zu vermeiden?

- **Evaluationsprotokoll & Metriken:**

- Warum ist der **mittlere fragenbasierte F1-Score** die primäre Metrik (Gleichgewicht aus Precision und Recall auf Chunk-Ebene)?
- Wie wird ein Perfect Match bei Zero-Gold definiert (Gold = [] und Pred = [] $\implies$ F1 = 1,0)?
- Disziplin: Hyperparameter-Optimierung ausschließlich auf Dev; Bestätigung auf Validation; einmalige Auswertung auf Test.

- **Vergleichs-Baselines:**

- *Random Top-1*: Gleichverteilte Zufallsauswahl eines Chunks (gemittelt über 100 feste Seeds).
- *Most-Frequent Dev Answer*: Konstante Vorhersage des im Dev-Set am häufigsten benötigten Gold-Sets.
- *Always Abstain*: Vorhersage von [] für jede Frage.

Empfohlene Quellen & Zitationszweck

- **Rajpurkar et al. [2018]**: Begründung plausibler Zero-Gold-Distraktoren zur Überprüfung der Enthaltungsfähigkeit.
- **Muennighoff et al. [2023]**: Standardisierte IR-Evaluationsmetriken.

Verbindliche experimentelle Eckdaten (Handover-Protokoll)

Statistik des Datensatzes über Korpus-Ebenen und Datensplits.

Split / Ebene	Gesamt	Beantwortbar (1-Gold)	Beantwortbar (2-Gold)	Zero-Gold ([])
Development	432	339	19	74
Validation	144	114	7	23
Test	144	115	6	23
Fragen Gesamt	720	568	32	120
Korpus-Ebene	Chunks	Anteil Chunks	Wörter Gesamt	Mittlere Länge
General Regulation	133	66,17 %	8 091	60,83 Wörter
Exemplary Study Plan	36	17,91 %	1 333	37,03 Wörter
Program Appendix	30	14,93 %	674	22,47 Wörter
Front Matter	2	1,00 %	96	48,00 Wörter
Korpus Gesamt	201	100,00 %	10 194	50,72 Wörter

5 Ergebnisse und Evaluation (Results & Evaluation)

Leitfragen für diesen Abschnitt

- **RQ1: Repräsentationsvergleich (Dev-Leaderboard):**
 - Warum führt Multilingual E5 das Feld an (Dev-F1 = 0,647)?
 - Warum schneidet TF-IDF mit F1 = 0,570 überraschend stark ab? (Diskriminative administrative Terme wie *Prüfungsausschuss*, *Modulprüfung*, *Kompensation*, *SWS*).
 - Warum bricht Sentence-BERT mit F1 = 0,399 ein? (Fehlende lexikalische Exaktheit; semantische Nähe nah verwandter administrativer Klauseln führt zu Verwechslungen).
- **RQ2: Selektoren & Schwellenwert-Enthaltung:**
 - Warum ist Top-1 + Threshold die überlegene Selektionsregel?
 - Wie verhalten sich reines Top-1 (keine Enthaltung, Null-Punkte bei Zero-Gold) und reines Thresholding (zu viele Chunks selektiert, Präzisionseinbruch)?
 - Wie schlägt sich die relative Marge im Vergleich?
- **Validierung und Test-Evaluation:**
 - Wie performt die Gewinner-Konfiguration (E5 + Top-1 + Threshold 0,8396) auf Validation (F1 = 0,611, EM = 0,604) und auf Test (F1 = 0,491, EM = 0,479)?
- **Fehleranalyse (Error Analysis) – Zentraler Diskussionspunkt:**
 1. *Strukturelle Obergrenze:* Top-1 kann Fragen mit 2 Gold-Chunks theoretisch maximal mit F1 = 0,667 beantworten ($P = 1,0$, $R = 0,5$).
 2. *Enthaltungsfehler:* Falsche Enthaltungen bei beantwortbaren Fragen vs. Halluzinationen bei Zero-Gold.
 3. *Ungesehene Evidenz-Subkorpora:* Die 8 Testfragen zur Zugangsprüfung (Q0153–Q0160) basieren auf Chunks, die in Dev/Val nie vorkamen, und schlugen kollektiv fehl.
 4. *Striktheit des Gold-Standards:* Valide Alternativ-Chunks in der Prüfungsordnung, die formal als Fehler gewertet wurden (*minimal intended evidence* vs. *exhaustive valid evidence*).
 5. *Post-hoc Sensitivitätsanalyse:* Transparente rechnerische Demonstration des Generalization Gaps (strikt als diagnostische Diskussion deklariert).

Empfohlene Quellen & Zitationszweck

- **Thakur et al. [2021] (BEIR):** Zur Erklärung, warum TF-IDF in spezifischen Fachkorpora bei distinktiven Fachwörtern dichten STS-Modellen überlegen sein kann.
- **Büttner and Habernal [2024] & Wrzalik and Krechel [2021]:** Zur Einordnung von Fehlklassifikationen in deutschen Rechts- und Regelungstexten.

Verbindliche experimentelle Eckdaten (Handover-Protokoll)

Vergleich der besten Konfigurationen je Repräsentation und Selektorfamilie auf dem Development-Split (432 Fragen).

Repräsentation	Selektor	Parameter	Fragen-F1	Exact Match	Precision	Recall
E5	Top-1 + Thresh.	$\theta = 0,8396$	0,647	0,637	0,653	0,645
E5	Relative Margin	$\gamma = 0,0025$	0,631	0,620	0,637	0,628
E5	Top-1	$k = 1$	0,617	0,604	0,623	0,715
E5	Threshold	$\theta = 0,8665$	0,494	0,366	0,458	0,628
TF-IDF	Relative Margin	$\gamma = 0,2350$	0,570	0,558	0,576	0,567
TF-IDF	Top-1 + Thresh.	$\theta = 0,0999$	0,567	0,553	0,574	0,564
TF-IDF	Top-1	$k = 1$	0,551	0,537	0,558	0,641
TF-IDF	Threshold	$\theta = 0,1277$	0,487	0,366	0,460	0,571
Sentence-BERT	Top-1 + Thresh.	$\theta = 0,6751$	0,399	0,396	0,400	0,398
Sentence-BERT	Relative Margin	$\gamma = 0,0050$	0,387	0,382	0,389	0,385
Sentence-BERT	Top-1	$k = 1$	0,374	0,368	0,377	0,434
Sentence-BERT	Threshold	$\theta = 0,7095$	0,358	0,280	0,334	0,442

6 Fazit (Conclusion)

Leitfragen für diesen Abschnitt

- **Synthese der Hauptideen:** Was ist die wesentliche wissenschaftliche Lektion aus der Gegenüberstellung von Repräsentationen und Selektoren?
- **Bedeutung der Selektionsschicht:** Warum zeigt die Arbeit, dass nicht allein das Embedding, sondern insbesondere die Entscheidungsregel (Schwellenwert-Filterung und Enthaltung) über die Zuverlässigkeit des Retrievals entscheidet?
- **Praktische Implikation:** Was bedeutet dies für die Entwicklung künftiger Chatbot- und RAG-Systeme für universitäre Verwaltungstexte?

7 Limitationen und zukünftige Arbeiten (Limitations & Future Work)

Leitfragen für diesen Abschnitt

- **Korpus- und Domäneneinschränkung:** Beschränkung auf ein einziges Dokument (Prüfungsordnung BA CL 2026) mit 201 Chunks; Generalisierbarkeit auf andere Fachordnungen oder Gesetze bleibt zu prüfen.
- **Strukturelle Top-1-Deckelung:** Unfähigkeit des Top-1-Ansatzes, Multi-Chunk-Evidenz vollständig abzurufen; Bedarf an adaptiven k -Selektoren.
- **Nicht evaluierte Modellfamilien:** Im Experiment wurden BM25, neuronale Cross-Encoder (Re-Ranking), hybrides Sparse-Dense-Retrieval sowie generative Reader nicht getestet.
- **Evaluationsmetrik:** Der Gold-Standard definiert ein minimal intendiertes Belegset, schließt semantisch äquivalente Alternativklauseln jedoch bisher als Fehler ein.

- **Zukünftige Forschungsansätze:** Hybride Retrieval-Verfahren, Cross-Encoder-Reranking und End-to-End-Evaluierung mit RAG-Readern.

Empfohlene Quellen & Zitationszweck

- **Karpukhin et al. [2020]:** Cross-Encoder Reranking als natürlicher nächster Schritt nach Bi-Encoder-Filterung.
- **Thakur et al. [2021]:** Hybrides Retrieval (BM25 + Dense) zur Kombination lexikalischer Präzision und semantischer Weite.

References

- Marius Büttner and Ivan Habernal. Answering legal questions from laymen in German civil law system. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 2015–2027. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.eacl-long.122.
- Yonatan Geifman and Ran El-Yaniv. SelectiveNet: A deep neural network with an integrated reject option. In *Proceedings of the 36th International Conference on Machine Learning*, pages 2151–2159. PMLR, 2019.
- Vladimir Karpukhin, Barlas Oguz, Sewon Min, Patrick Lewis, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 6769–6781. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.emnlp-main.550.
- Niklas Muennighoff, Nouamane Tazi, Loic Magne, and Nils Reimers. MTEB: Massive text embedding benchmark. In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2014–2037. Association for Computational Linguistics, 2023. doi: 10.18653/v1/2023.eacl-main.148.
- Pranav Rajpurkar, Robin Jia, and Percy Liang. Know what you don’t know: Unanswerable questions for SQuAD. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 784–789. Association for Computational Linguistics, 2018. doi: 10.18653/v1/P18-2124.
- Nils Reimers and Iryna Gurevych. Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992. Association for Computational Linguistics, 2019. doi: 10.18653/v1/D19-1410.
- Nils Reimers and Iryna Gurevych. Making monolingual sentence embeddings multilingual using knowledge distillation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 4512–4525. Association for Computational Linguistics, 2020. doi: 10.18653/v1/2020.emnlp-main.365.
- Gerard Salton, Anita Wong, and Chung-Shu Yang. A vector space model for automatic indexing. *Communications of the ACM*, 18(11):613–620, 1975. doi: 10.1145/361219.361220.
- Karen Spärck Jones. A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1):11–21, 1972. doi: 10.1108/eb026526.

- Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*, 2021.
- Liang Wang, Nan Yang, Xiaolong Huang, Binxing Jiao, Linjun Yang, Daxin Jiang, Rangan Majumder, and Furu Wei. Text embeddings by weakly-supervised contrastive pre-training. *arXiv preprint arXiv:2212.03533*, 2022. doi: 10.48550/arXiv.2212.03533.
- Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. Multilingual E5 text embeddings: A technical report. Technical Report MSR-TR-2024-45, Microsoft Research, 2024.
- Marco Wrzalik and Dirk Krechel. GerDaLIR: A German dataset for legal information retrieval. In *Proceedings of the Natural Legal Language Processing Workshop 2021*, pages 123–128. Association for Computational Linguistics, 2021. doi: 10.18653/v1/2021.nllp-1.13.